



UNIVERSIDAD
POLITÉCNICA
DE MADRID



Universidad Politécnica de Madrid
**Escuela Técnica Superior de Ingeniería Aeronáutica
y del Espacio**

Máster Universitario en Ingeniería Aeronáutica

**Proyecto sobre predicción a corto
plazo de generación en parques
eólicos**

GRUPO 08

Hugo García de Andrés
Raúl Moreno Gómez
Rafael Tapia Doblas
Marc Vila Alperi

Especialidad: Intensificación en Aeronaves
Asignatura: Sistemas Eólicos Terrestres y Oceánicos

Madrid, 29 de Diciembre de 2022

Índice de Contenidos

1. Introducción	2
2. Modelo A: ANN para $hp = 1$	3
2.1. Tipo de modelo seleccionado, ANN	3
2.2. Datos de entrada	3
2.3. Porcentaje de error	4
3. Modelo B: ANN para $hp = 12$	6
3.1. Tipo de modelo seleccionado	6
3.2. Datos de entrada	6
3.3. Porcentaje de error	7
4. Conclusiones	7
5. Referencias	7

Lista de símbolos

ANN	Modelo no lineal de redes neuronales, <i>Artificial Neural Network</i>
ARX	Modelo autorregresivo con variable exógena
hp	Horizonte de predicción
p	Número de observaciones de potencia más recientes
RMSE	Error cuadrático medio, <i>Root-Mean-Square Error</i>
X_t	Serie temporal multivariable que contiene m variables medidas
y_t	Serie temporal de potencia generada por un parque eólico
Z_t	Serie temporal de n variables meteorológicas
\hat{y}_{t+hp}	Predicción de potencia para el instante $t + hp$

1. Introducción

La predicción de energía eólica es de vital importancia ya que el mercado de la energía se rige por un principio basado en que la energía consumida en cada instante es la misma que la energía producida. Debido a esto, ya que la generación de energía eólica es un proceso altamente estocástico, porque el viento atmosférico lo es, es necesario realizar una buena predicción para poder competir en el mercado de la energía.

Las predicciones de energía eólica de mayor importancia se centran en los horizontes temporales, hp , de 0-24 h. Horizontes temporales pequeños sirven para ajustar la producción del resto de fuentes energéticas distintas de la eólica en función de la predicción de esta, y horizontes de 12 h se emplean para la competición y venta de energía en el mercado.

En el informe se muestran y detallan dos modelos de predicción de potencia eólica optimizados para cada horizonte de predicción y para un emplazamiento eólico determinado. Se trata de dos modelos de predicción a corto plazo que se han desarrollado a partir de los datos del parque eólico proporcionados (datos del año 2013) y de un conjunto de funciones numéricas implementadas en **MATLAB**.

Los modelos de predicción que se han estudiado para ambos horizontes son los modelos autorregresivos con variable exógenas (basados en una ecuación lineal), **ARX**, y los modelos no lineales de redes neuronales (basados en una ecuación no lineal), **ANN**. Estos requieren de una serie de datos temporales de entrada para realizar la predicción de potencia los cuales en este caso son: serie temporal de potencia, y_t , serie temporal de presión atmosférica, X_t , y serie temporal de predicción del módulo de viento, Z_t .

Con todo ello, se define de que la potencia generada en un parque eólico en un instante $t + hp$, será función de las observaciones más recientes de potencia, p , la predicción del módulo de viento en ese instante $t + hp$, la presión atmosférica y el conjunto de parámetros derivados del modelo de predicción empleado, Θ .

$$\hat{y}_{t+hp} = f(y_t, y_{t-1}, \dots, y_{t-p+1}, X_t, Z_{t+hp}, \Theta). \quad (1.1)$$

2. Modelo A: ANN para $hp = 1$

2.1. Tipo de modelo seleccionado, ANN

Para realizar predicciones con un horizonte de 1 hora, se ha seleccionado un modelo de red neuronal, ANN (*Artificial Neural Network*), en contraposición de utilizar un modelo ARX. Se debe a que realizando pruebas sobre los modelos de predicción de este informe se pudo observar que mientras que los modelos ARX son modelos sencillos que requieren poco coste computacional son los modelos ANN los que proporcionan predicciones mejores a cambio de aumentar considerablemente su coste computacional.

Para ello en este apartado se realizará tanto una definición de los principales parámetros de la red ANN como un estudio de la estructura óptima y de sus datos óptimos de entrada.




Figura 2.1: Función de autocorrelación parcial de la serie temporal de potencias, y_t , en intervalos de 1 hora.

En la Figura 2.1 se ha representado la función de autocorrelación parcial de la serie temporal de potencias, y_t , en intervalos de 1h. Como se puede observar, la correlación es significativa hasta 3 horas después de tomar una muestra, por lo que el orden de autorregresión óptimo será $p = 3$. Escoger valores más elevados provocaría un sobreajuste notable de la predicción para los valores de entrada dados.

2.2. Datos de entrada

En cuanto a los datos de entrada se ha considerado óptimo incorporar todos los datos disponibles de la predicción ya que aunque presenten poca correlación, las pre-

dicciones del módulo del viento, Z_t , y las medidas de presión atmosférica, X_t , pueden ayudar a obtener errores menores e incluirlas no aumenta demasiado el coste computacional. Para la estructura de la ANN se definen 5 nodos de entrada, 4 para cada variable y uno de bias, tal como recomienda Amidi [1]. Habrá un único nodo de salida para la variable \hat{y}_{t+1} con diferentes números de capas ocultas [1:5] con número de nodos variables de 32 a 1. El estudio de estas estructuras se detallará en el siguiente apartado.

2.3. Porcentaje de error

Una vez definidos los principales parámetros para definir la red neuronal se procede a realizar un estudio de diferentes estructuras de redes neuronales para encontrar un modelo que pueda predecir de manera correcta los valores de potencia y_t .

Según Amidi [1], el número de capas ocultas tiene relación con la capacidad de la red de tener en cuenta tendencias. Una manera de poder cuantificar este fenómeno y validar una red para una gran cantidad de muestras es comprobar la varianza del error medido para diferentes estructuras y tamaños de la red. Valores bajos de varianza con diferentes muestras pueden indicar que la red es consistente con las predicciones que realiza mientras que valores altos pueden indicar lo contrario, es decir, sobreajuste. Para realizar este estudio se crean 40 redes ANN con diferentes tipos de estructuras, desde estructuras simples y pequeñas ([5 1]) hasta estructuras grandes y complejas ([5 32 32 32 32 32 1]). A continuación se entrenarán con el conjunto de datos de estudio y se pondrán a prueba calculando el error en la predicción de segmentos aleatorios dentro de la muestra para poder calcular la varianza del error medido, es decir, proporcionando segmentos de 3 horas aleatorios dentro de la muestra para predecir la hora siguiente.

En la Figura 2.2, se observan los resultados del error medio cuadrático, RMSE, medido en función de la varianza normalizada, σ_{std} . Se tienen dos grupos de puntos, uno que presenta alta varianza y alto error medio, correspondiente a las redes pequeñas con número reducido de neuronas por capa y otro que presenta una varianza reducida y error medio bajo, correspondiente a las redes más grandes estudiadas. Se comprueba que al aumentar el tamaño de la red el error medido disminuye de manera notable e incluso en mayor medida disminuye la varianza de los resultados medidos, pero a un gran riesgo de presentar sobreajuste que debería de ser comprobado.

En la Figura 2.3 se muestran los resultados de los errores medios cuadráticos para los ensayos aleatorios realizados mediante una validación cruzada (*cross validation*), la cual consiste en reentrenar las redes seleccionadas previamente con parte de la muestra y reservar 2 meses de la muestra para realizar predicciones de segmentos de 6 horas aleatorios. Con esto se comprueba si la red muestra signos de sobreajuste y con ello poder decidir una red correcta para el horizonte de 1 hora.




Figura 2.2: Error medio cuadrático, RMSE, en función de la varianza normalizada, σ_{std} , para diferentes redes de estudio.

La red mostrada de color morado, la de menor error medio, es la seleccionada para el modelo A de predicción, cuyos parámetros se muestran en la Tabla 2.1, es la que presenta el mejor error medio, mientras que el resto muestran signos de sobreajuste muy notables, correspondientes sobre todo a las redes con entруктурas mayores.




Figura 2.3: Error medio cuadrático, RMSE, en función del número de ensayos, N .

Tabla 2.1: Parámetros de la red ANN seleccionada para el modelo A.

p	Estructura	RMSE [%]	σ_{std}
3	[5 4 1]	7.68	0.1497

3. Modelo B: ANN para $hp = 12$

3.1. Tipo de modelo seleccionado

Para realizar predicciones con un horizonte de 12h, se ha seleccionado un modelo no lineal de redes neuronales, ANN, con un orden de autorregresión $p = 1$ puesto que se ha considerado suficiente tener en cuenta el último dato de potencia.

El número de capas y neuronas ocultas se ha seleccionado a partir de diversos estudios realizados sobre el tema. Si bien Guoqiang Zhang et al. [3] sugieren que una única capa oculta es suficiente para la mayoría de casos, se ha elegido emplear dos capas para minimizar el número de neuronas ocultas por capa y así el tiempo de entrenamiento. De esta manera también se mejora la capacidad de generalización de la red.

El número de neuronas debe ser suficientemente grande para modelizar correctamente el proceso, pero no demasiado grande pues aparecerían problemas de sobreajuste (*overfitting*). Sachdev [2] proporciona algunas directrices tales como que el número de neuronas ocultas debe encontrarse entre el tamaño de la capa de entrada y el de la capa de salida y que su número debe ir descendiendo entre capas. El número de neuronas ocultas seleccionado se ha obtenido, además, a través de sendas pruebas con distintas configuraciones eligiendo, finalmente, 4 neuronas distribuidas en 2 capas ([3 1]).

3.2. Datos de entrada

El modelo requiere los datos recientes de potencias, y_t , y las predicciones del módulo de viento, Z_t . Se ha descartado emplear las mediciones de presión atmosférica, X_t , pues se ha observado una correlación parcial nula en horizontes temporales de 12h.

Tabla 3.1: Raíz del error cuadrático medio, RMSE, de las distintas predicciones y entrenamientos.

RMSE de la Predicción (%)	1ºCuatrimestre	2ºCuatrimestre	3ºCuatrimestre	4ºCuatrimestre
Entrenamiento 1	16.08	15.51	13.88	13.00
Entrenamiento 2	16.08	15.81	17.49	12.95
Entrenamiento 3	19.81	15.81	13.88	13.00
Entrenamiento 4	16.19	19.32	13.88	12.95
Entrenamiento 5	16.08	15.51	13.92	20.63
Media	16.25	16.39	14.61	14.51

3.3. Porcentaje de error

Para estimar el porcentaje de error para futuros años, se ha realizado una validación cruzada del modelo (*cross-validation*), dividiendo el año en cuatrimestres y entrenando el modelo con tres cuatrimestres para predecir el cuarto restante. Para eliminar la varianza introducida por el algoritmo Levenberg-Marquardt, se ha realizado cada entrenamiento 5 veces y se ha calculado la media aritmética de todas las predicciones. El resultado se muestra en la Tabla 3.1.

A la luz de los resultados, se puede prever un error de entorno el 15 % para las predicciones del año siguiente.

4. Conclusiones

Se concluye en este informe que, mientras que las redes neuronales (ANN) producen mejores predicciones de manera general, estas presentan un desafío a la hora de determinar su estructura. Esto se constata en que una mala elección del modelo puede dar lugar a sobreajustes, por ejemplo, al implementar una red de gran tamaño. También se ha visto que, para realizar una predicción en el horizonte de 1 y 12 horas la redes que, *a priori*, parecen ofrecer mejores resultados estas pueden llevar a grandes sobreajustes por memorización de los datos de entrenamiento. La correcta elección de la estructura de la red se ve dificultada, además, por el alto coste computacional de entrenamiento.

Por otra parte una vez realizados los entrenamientos de las redes se ha podido comprobar que las redes pequeñas para grandes conjuntos de datos funcionan mejor para realizar predicciones en horizontes temporales reducidos. Finalmente, se ha aplicado la validación cruzada de las redes de ambos modelos para asegurar el correcto funcionamiento de la predicción y estimar el error en las previsiones de futuros años.

5. Referencias

- [1] Afshine Amidi and Shervine Amidi. *Super VIP Cheatsheet: Machine Learning*, 2018. Stanford University.
- [2] Harpreet Singh Sachdev. Choosing number of hidden layers and number of hidden neurons in neural networks, 2020.
- [3] Guoqiang Zhang, B Eddy Patuwo, and Michael Y Hu. Forecasting with artificial neural networks:: The state of the art. *International journal of forecasting*, 14(1):35–62, 1998.